




**Ministério da Educação**  
**Instituto Federal de Mato Grosso**  
**Campus Cuiabá – Cel. Octayde Jorge da Silva**  
**Departamento de Computação**



# **Deteção de Anomalias em Redes de Computadores usando Autoencoders**


## **VAE com Python e PyTorch**

**Discentes:** **Heloíse Bastos e Joicy Kelly**

**Docente:** Ruy de Oliveira

IFMT - Campus Cuiabá

2024




# Agenda

<b>03</b>	<b>Introdução</b>
<b>05</b>	<b>Objetivo</b>
<b>06</b>	<b>Referencial Teórico</b>
<b>14</b>	<b>Metodologia</b>
<b>15</b>	<b>Resultados e Discussões</b>
<b>16</b>	<b>Conclusões</b>
<b>17</b>	<b>Referência Bibliográfica</b>




- 
- The diagram illustrates a hybrid network architecture. At the top, a mobile phone and a landline phone are connected to a central hub (represented by a globe) via wireless signals. This hub is also connected to a server rack. The server rack is connected to a network switch, which in turn connects to a laptop and a desktop computer. The laptop and desktop computer are also connected to the server rack via wireless signals. The server rack is also connected to a network switch, which is connected to a desktop computer. The desktop computer is also connected to the server rack via wireless signals. The server rack is also connected to a network switch, which is connected to a desktop computer. The desktop computer is also connected to the server rack via wireless signals.



# Introdução


- **Detecção de anomalias**
- **Ataques cibernéticos**
- **ataques de negação de serviço (DoS)**





# Objetivos


O objetivo do trabalho é desenvolver um modelo de rede neural utilizando o Autoencoders VAE , para a detecção de de anomalias em redes de computadores, utilizando o dataset NSL-KDD.



# Referencial Teórico


- **Biblioteca de código aberto ;**
- **Facebook (Meta);**
- **Computação científica;**
- **Construção e manipulação de redes neurais ;**






# Referencial Teórico

- Camada de entrada
- Camada Oculta
- Camada de Saída






# Referencial Teórico

## Hiperparâmetros e componentes de configuração

- **Funções de Ativação Camada Ocultas;**
- **Quantidade de Amostras e Tamanho do Conjunto de Dados;**
- **Função de Perda (Loss Function);**
- **Otimizadores;**
- **Taxa de Aprendizado (Learning Rate);**






# Referencial Teórico

## **Parâmetros de Treinamento e Avaliação**


- **Épocas; Número de épocas;**
- **Métricas de Avaliação;**



# Referencial Teórico

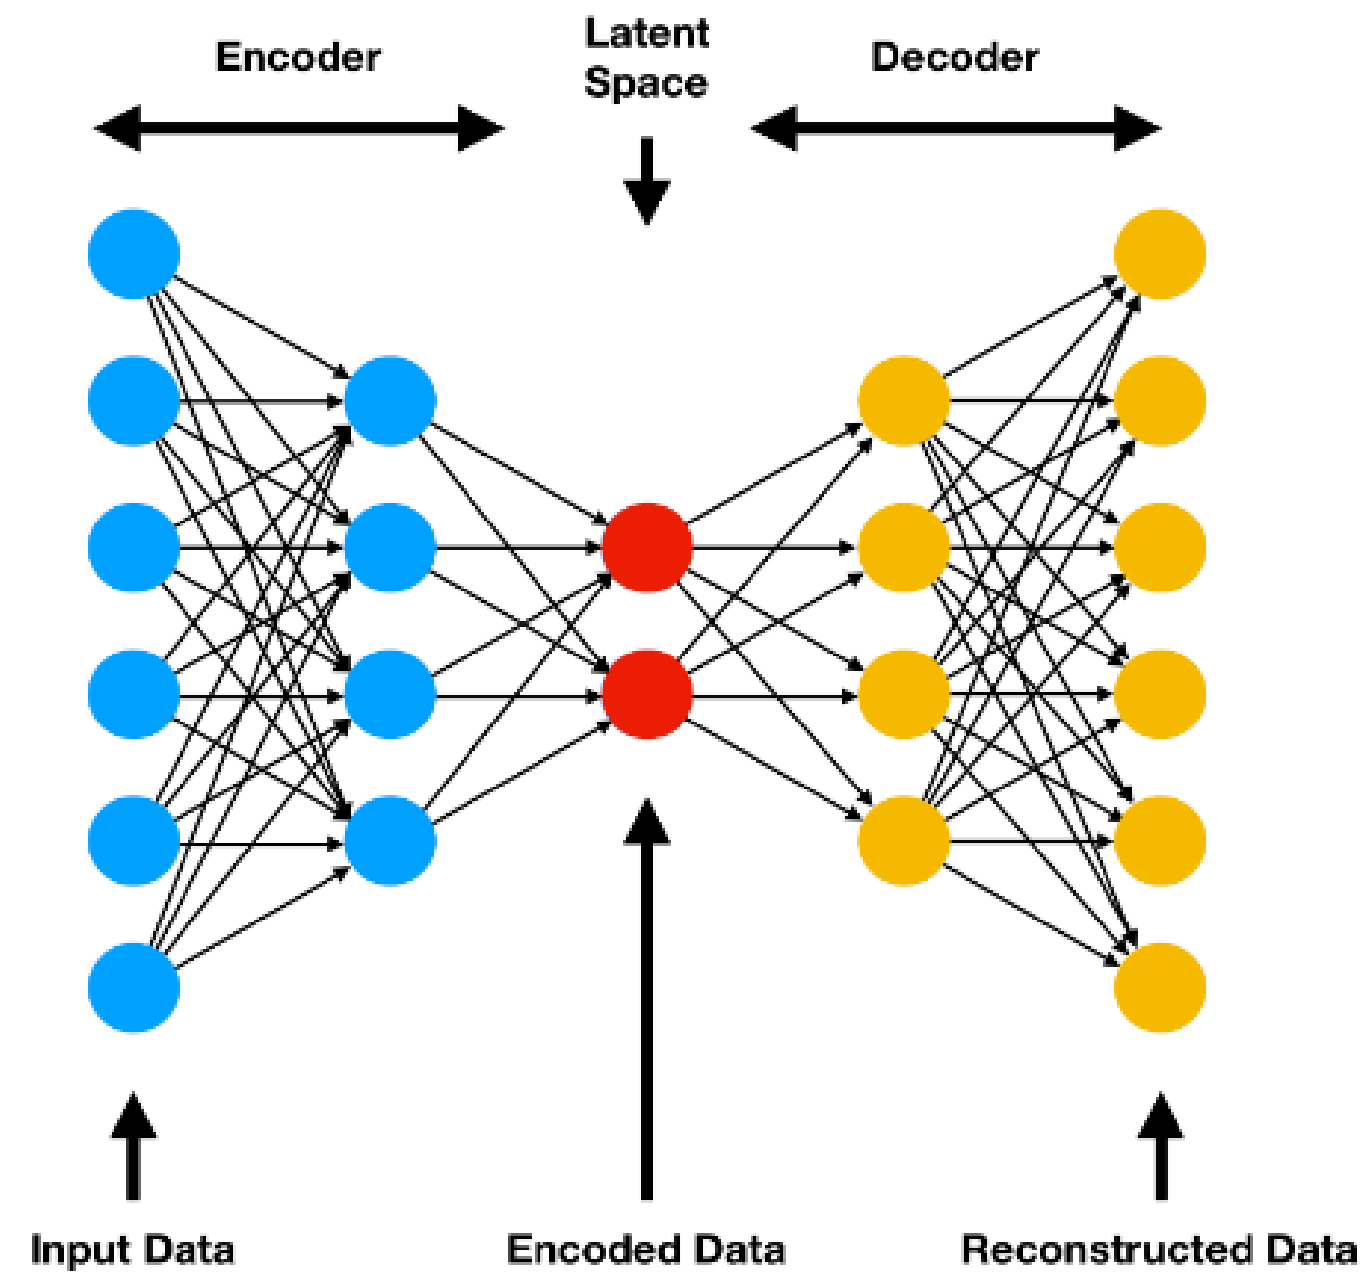
## Dataset NSL


- Os dados de NSL-KDD contêm 42 atributos;
- Os registros são classificados em classe normal ou conexões maliciosas;



# Referencial Teórico

## Autoencoder






# Referencial Teórico


## Autoencoder

- Compressão de dado
- Aprendizado de Máquina não Supervisionado
- Codificador (encoder ) e o decodificador (decoder )

Esquema Autoenconders



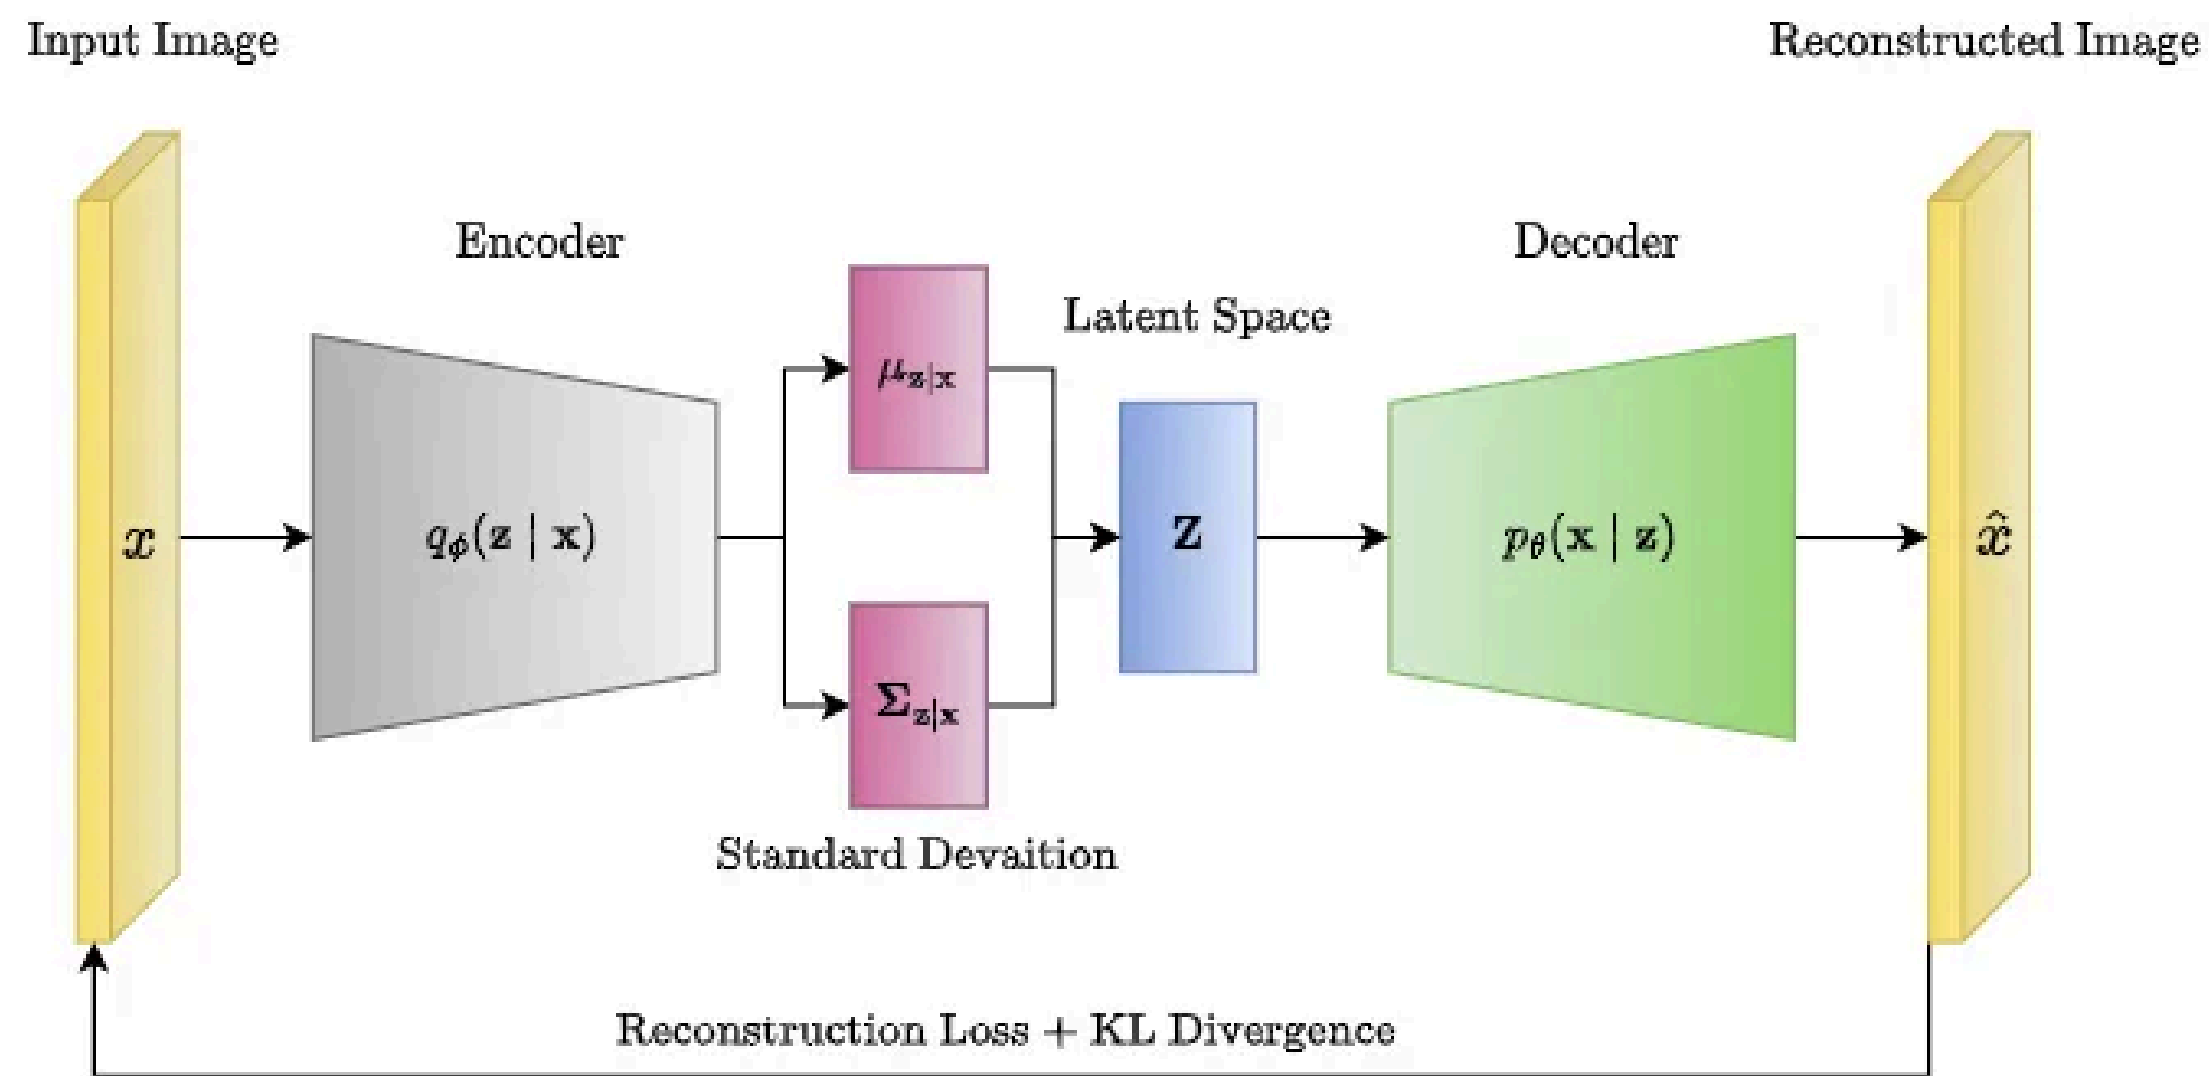
Fonte: Chollet (2016)




# Referencial Teórico

## Autoencoders VAE


- Codificação;
- Amostragem;
- Decodificação;
- Função de Perda;






# Metodologia

- **Estudo dos Conceitos** : dados de redes de computadores, detecção de anomalias, e Autoencoders VAE
- **Implementação do Código** : implementação do modelo com dados no conjunto de dados Dataset NSL
- **Validação do modelo**: uso de métricas que medem a taxa de previsão do modelo



# Resultados e Discussões


- **Treinado por 100 época**
- **Diminuição progressiva do loss**
- **Capaz de aprender com os dados**
- **Capacidade de reconstrução**



# Resultados e Discussões

- **Dados anômalos : erro de reconstrução**
- **Métricas de Validação**
- **Ajuste de Hiperparâmetros**





# Referência Bibliográfica

BIOLOGIX. Redes Neurais: uma vertente da Inteligência Artificial inspirada no funcionamento do cérebro humano. 2024. [S. l.]. Acesso em: 28 out. 2024. Disponível em: <<https://www.biologix.com.br/2024/07/19/redes-neurais-uma-vertente-da-inteligencia-artificial-inspirada-no-funcionamento-do-cerebro-humano/>>.

COMINI, J. P. M. Detecção de anomalias utilizando autoencoder variacional. 2019. Trabalho de Conclusão (Graduação em Ciência da Computação) - Universidade Estadual Paulista "Júlio de Mesquita Filho". Disponível em: <<https://repositorio.unesp.br/server/api/core/bitstreams/7e48d35b-3699-4286-8849-cfc768e57a88/content>>.

M, H. Z. NSL-KDD. 2018. [S. l.]. Acesso em: 28 out. 2024. Disponível em: <<https://www.kaggle.com/datasets/hassan06/nsldata>>.

RAMOS, M. O que é Variational Autoencoder (Autoencoder Variacional – VAE)? 2023. Acesso em: 28 out. 2024. Disponível em: <<https://glossario.maconramos.com/glossario/o-que-e-variational-autoencoder-autoencoder-variacional-vae/>>.

SILVA, H. D. d. Detecção de ataques de negação de serviço em redes de computadores através de previsões por séries temporais. 2018. Dissertação (Mestre em Modelagem Computacional em Ciência e Tecnologia) - Universidade Federal Fluminense. Disponível em: <<http://mcct.uff.br/wp-content/uploads/sites/454/2019/10/Disserta%C3%A7%C3%A3o-Henrique-Dornel-da-Silva-defendeu-em-15-08-2018.pdf>>.

STEVEN, F. Variational Autoencoders are Beautiful. 2019. Accessed: October 4, 2024. Disponível em: <<https://www.compthree.com/blog/autoencoder/>>.

**Obrigada**